

Исследование и улучшение модели

При выводе явной формулы для вектора Θ коэффициентов линейной регрессионной модели:

$$\hat{\Theta} = (X^T X)^{-1} X^T Y.$$

мы (неявно) предполагали, что матрица $X^T X$ обратима, т.е. её столбцы линейно независимы. Однако на практике может оказаться, что *факторы* являются *линейно зависимыми*. Заметим, что вероятность того, что среди факторов есть линейно зависимые тем больше, чем большее количество факторов включается в модель. Хотя на первый взгляд, может показаться, что чем больше в модели факторов (предикторов), тем точнее эта модель, на само деле это не так. Линейная зависимость факторов носит название *мультиколлинеарности*.

Мультиколлинеарность - это (явная или стохастическая) линейная зависимость двух или нескольких факторов (объясняющих переменных).

Следствием мультиколлинеарности является вырожденность матрицы $X^T X$ (т.е. равенство: $\det(X^T X) = 0$), где

$$X = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1j} & \dots & x_{1m} \\ 1 & x_{21} & x_{22} & \dots & x_{2j} & \dots & x_{2m} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 1 & x_{i1} & x_{i2} & \dots & x_{ij} & \dots & x_{im} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nj} & \dots & x_{nm} \end{pmatrix}$$

а значит, невозможность найти решение (т.е. вектор коэффициентов регрессионной модели) по формуле:

$$\hat{\Theta} = (X^T X)^{-1} X^T Y.$$

Здесь \mathbf{Y} – вектор (известных) значений переменной отклика.

При применении итерационных методов решения задачи, которая формулируется в Методе наименьших квадратов, построенная итерационная последовательность может не иметь предельных точек.

В случае, когда $\det(\mathbf{X}^T \mathbf{X})$ близок к 0 (зависимость между факторами стохастическая), следствиями мультиколлинеарности являются следующие обстоятельства:

- 1) Оценки параметров становятся ненадежными (обнаруживают большие ошибки), причём по мере увеличения числа наблюдений (размера обучающей выборки) оценки сильно изменяются (даже могут поменять знак), что делает прогнозирование на их основе невозможным.
- 2) Параметры линейной регрессии теряют экономический (или иной) смысл, они не поддаются интерпретации.
- 3) Становится невозможным определить изолированное влияние каждого фактора на значение переменной отклика.

Рассмотрим некоторые *характеристики качества регрессионной модели*.

Заметим, что при выводе сводной информации о модели наряду с её коэффициентами выводятся ещё некоторые характеристики, в частности, величины :

- **Коэффициент детерминации (Multiple R-squared)** и
- **Исправленный коэффициент детерминации (Adjusted R-squared)**

summary(mymodel)

```

Residuals:
    Min       1Q   Median       3Q      Max
-3.6560 -1.7738 -0.7540  0.6493  9.3139

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
totsquare    0.0519874  0.1177009   0.442   0.665
livesquare   0.1386667  0.1465748   0.946   0.360
floor        -0.0089039  0.2659979  -0.033   0.974
height       -0.2524347  0.2125690  -1.188   0.255
distcenter   0.1461910  0.1682269   0.869   0.399
distmetro    -0.0002076  0.0009206  -0.225   0.825

Residual standard error: 3.273 on 14 degrees of freedom
Multiple R-squared:  0.9395,    Adjusted R-squared:  0.9136
F-statistic: 36.25 on 6 and 14 DF,  p-value: 9.547e-08

```

Коэффициент детерминации (Multiple R-squared) :

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (1)$$

где \hat{y}_i – спрогнозированное значение переменной отклика для i -ой строки обучающей выборки; y_i – истинное значение переменной отклика (в i -ой строке обучающей выборки); \bar{y} – среднее значение переменной отклика.

Очевидно, что чем **коэффициент детерминации** ближе к 1 (т.е., чем числитель ближе к 0), тем точнее прогноз, полученный с помощью линейной регрессионной модели. (Действительно, величина в числителе дроби характеризует различие между прогнозом и фактическими значениями переменной отклика, а значит, чем эта величина меньше, тем точнее прогноз; знаменатель дроби – есть дисперсия переменной отклика (с точностью до множителя)). В приведённом выше примере $R^2 \approx 0,94$, что означает достаточно высокую точность прогноза.

Вместе с тем, с увеличением числа предикторов коэффициент детерминации возрастает, а значит, необоснованно «завышает оценку качества» прогноза, полученного с помощью линейной регрессионной модели. Для того, чтобы получить более адекватную оценку качества прогноза, используют так называемый «исправленный» коэффициент детерминации (**Adjusted R-squared**):

$$R_{adj}^2 = 1 - (1 - R^2) \frac{n-1}{n-m-1}, \quad (2)$$

(здесь, как и ранее, n – число наблюдений (число строк в обучающей выборке), m – число факторов (предикторов) (число в обучающей выборке минус 1). Введённый в (2) коэффициент представляет собой штраф за большое число предикторов.

Подробнее о характеристиках линейной регрессионной модели см. в статье [«Оценка результатов линейной регрессии»](#)

Вычислим попарные коэффициенты корреляции между предикторами (а также между каждым из предикторов и переменной отклика) для рассмотренного выше примера:

```
myData = read.csv("myflats.txt", sep = '\t', header=TRUE)
myData
rm = cor(myData)
rm
```

| | totsquare | livesquare | floor | height | distcenter | distmetro | price |
|------------|--------------|------------|------------|--------------|-------------|------------|-------------|
| totsquare | 1.000000000 | 0.9510794 | -0.3054832 | 0.003209003 | -0.18622246 | -0.5460350 | 0.78791852 |
| livesquare | 0.951079355 | 1.0000000 | -0.1914513 | 0.105225446 | -0.12384035 | -0.5127576 | 0.77744783 |
| floor | -0.305483161 | -0.1914513 | 1.0000000 | 0.514470424 | 0.10466631 | 0.5249853 | -0.25233447 |
| height | 0.003209003 | 0.1052254 | 0.5144704 | 1.000000000 | 0.04170783 | 0.2044663 | -0.11189253 |
| distcenter | -0.186222455 | -0.1238404 | 0.1046663 | 0.041707831 | 1.000000000 | 0.2866833 | 0.05890125 |
| distmetro | -0.546034979 | -0.5127576 | 0.5249853 | 0.204466321 | 0.28668328 | 1.0000000 | -0.39274420 |
| price | 0.787918520 | 0.7774478 | -0.2523345 | -0.111892529 | 0.05890125 | -0.3927442 | 1.00000000 |

Естественно, диагональные элементы полученной корреляционной матрицы равны 1. Мы видим, что имеется сильная положительная корреляция между общей площадью квартиры (переменная **totsquare**) и жилой площадью (**livesquare**), поэтому имеет смысл исключить один из этих признаков (хотя, конечно, зависимость между ними нелинейная). Заметим, что влияние остальных признаков на цену квартиру существенно меньше, чем влияние фактора площади, причём факторы: «этаж», «количество этажей в доме» и «расстояние до метро» играют на понижение цены, остальные факторы – на повышение.

```
# Исключим 2-й фактор (livesquare)
myData = myData[-2]

# Пересчитаем корреляционную матрицу
rm = cor(myData)
rm
```

```

      totsquare      floor      height distcenter distmetro      price
totsquare  1.000000000 -0.3054832  0.003209003 -0.18622246 -0.5460350  0.78791852
floor      -0.305483161  1.0000000  0.514470424  0.10466631  0.5249853 -0.25233447
height      0.003209003  0.5144704  1.000000000  0.04170783  0.2044663 -0.11189253
distcenter -0.186222455  0.1046663  0.041707831  1.00000000  0.2866833  0.05890125
distmetro  -0.546034979  0.5249853  0.204466321  0.28668328  1.0000000 -0.39274420
price       0.787918520 -0.2523345 -0.111892529  0.05890125 -0.3927442  1.00000000

# Получим новую регрессионную модель (без livesquare)

mymodel = lm(price ~ -1+ totsquare + floor + height +
distcenter + distmetro, data = myData)
summary(mymodel)

      Min      1Q  Median      3Q      Max
-2.9597 -1.9119 -0.9866  0.8043  9.7132

Coefficients:
      Estimate Std. Error t value Pr(>|t|)
totsquare  0.1609714  0.0240531   6.692  7.2e-06 ***
floor      0.0488326  0.2579945   0.189   0.852
height    -0.2233471  0.2095962  -1.066   0.303
distcenter  0.1668685  0.1662162   1.004   0.331
distmetro -0.0005034  0.0008628  -0.583   0.568
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.262 on 15 degrees of freedom
Multiple R-squared:  0.9357,    Adjusted R-squared:  0.9142
F-statistic: 43.63 on 5 and 15 DF,  p-value: 2.062e-08

```

Обратите внимание, как изменились вероятности превышения (по модулю) абсолютного значения критерия Стьюдента! Кроме того, мы наблюдаем улучшение (хотя и незначительное) исправленного коэффициента детерминации, что говорит об улучшении качества модели.